

Product Backlog Completo — Edge Computing LLM

Projeto: Framework de avaliação de SLMs leves em ambientes Edge simulados

Entrega final: Setembro de 2026

Stack:

- Backend: Python (Django ou FastApi);
- Simulação: Docker (cgroups), Ollama API;
- Frontend: a definir.

Divisão de tempo: 6 sprints de 15 dias, sugestão de início 17/06/2026, sugestão de término 14/09/2026

Plano de Sprints (6 × 15 dias)

Sprint	Período	Tema	Itens	Pts
S1	17/06 – 01/07	Fundação: perfis + esqueleto Docker/Ollama	US-01, US-02, US-03, US-04, US-11, RNF-03, RNF-06	34
S2	02/07 – 16/07	Configuração + motor de execução	US-05, US-06, US-07, US-07b, US-08, US-09, US-10	42
S3	17/07 – 31/07	Execução robusta + coleta de métricas	US-11b, US-12, US-13, US-13b, US-14, US-15, US-17	50
S4	01/08 – 15/08	Multimodal + qualidade + análise estatística	US-06b, US-15b, US-16, US-20a, US-20b, US-22	44
S5	16/08 – 30/08	Frontend web + relatórios	US-18, US-19, US-20c, US-23, US-24, US-25	58
S6	31/08 – 14/09	Dashboard, comparação, qualidade final	US-21, US-26, RNF-01, RNF-02, RNF-04, RNF-05, RNF-07	49

Tabelas de Épicas

ID	Épico
EP-01	Gerenciamento de Perfis de Hardware

EP-02	Configuração de Benchmark
EP-03	Execução de Benchmark
EP-04	Coleta de Métricas
EP-05	Análise e Relatórios
EP-06	Interface Web
EP-07	Infraestrutura e Qualidade (RNFs)

Tabelas de Backlogs

ID	Backlog
EP-01 / US-01	Criar perfil de hardware
EP-01 / US-02	Editar perfil de hardware
EP-01 / US-03	Excluir perfil de hardware
EP-01 / US-04	Validar perfil vs. hardware real
EP-02 / US-05	Selecionar modelos SLM
EP-02 / US-06	Configurar prompts de teste textuais
EP-02 / US-06b	Configurar cenários multimodais
EP-02 / US-07	Definir número de execuções
EP-02 / US-07b	Fixar parâmetros de geração
EP-02 / US-08	Salvar configuração de benchmark
EP-02 / US-09	Carregar configuração pré-existente
EP-03 / US-10	Iniciar execução de benchmark
EP-03 / US-11	Aplicar restrições de hardware via Docker
EP-03 / US-11b	Garantir execução sequencial e isolada
EP-03 / US-12	Tratar falhas durante a execução
EP-03 / US-13	Configurar timeout por execução
EP-03 / US-13b	Separar cold start de warm inference
EP-04 / US-14	Coletar métricas de latência e throughput

EP-04 / US-15	Coletar métricas de consumo de recursos
EP-04 / US-15b	Registrar clock/temperatura da CPU
EP-04 / US-16	Coletar tamanho em disco e resposta textual
EP-04 / US-17	Persistir resultados de métricas
EP-05 / US-18	Exportar resultados em CSV
EP-05 / US-19	Exportar resultados em JSON
EP-05 / US-20	Agregar repetições estatisticamente
EP-05 / US-20b	Testes estatísticos de comparação
EP-05 / US-20c	Visualizar matriz comparativa e Pareto
EP-05 / US-21	Comparar benchmarks distintos
EP-05 / US-22	Avaliar qualidade das respostas
EP-06 / US-23	Telas de gestão de perfis
EP-06 / US-24	Tela de configuração de benchmark
EP-06 / US-25	Acompanhar execução em tempo real
EP-06 / US-26	Dashboard de resultados
EP-07 / RNF-01	Desempenho do orquestrador
EP-07 / RNF-02	Reprodutibilidade dos resultados
EP-07 / RNF-03	Portabilidade multiplataforma
EP-07 / RNF-04	Usabilidade da interface web
EP-07 / RNF-05	Observabilidade e logging
EP-07 / RNF-06	Segurança de dados locais
EP-07 / RNF-07	Testabilidade do framework
EP-07 / RNF-08	Extensibilidade para novos runtimes

EP-01 - Gerenciamento de Perfis de Hardware

ID	User Story	Critérios de Aceitação	Prioridade
01	Como usuário do framework, quero criar um perfil de hardware com nome, número de vCPUs e quantidade de RAM, para simular um dispositivo edge específico nos testes.	☐ É possível informar nome, vCPUs e RAM (em GB ou MB). ☐ O nome do perfil é único; nomes duplicados são rejeitados com mensagem clara. ☐ Valores não-numéricos ou negativos são bloqueados. ☐ O perfil criado é persistido e aparece na lista de perfis disponíveis. ☐ Os perfis-base do projeto (2cpu-2gb, 2cpu-4gb, 4cpu-4gb, 4cpu-8gb) podem ser criados sem erro.	
02	Como usuário, quero editar um perfil existente, para ajustar restrições sem precisar recriá-lo.	☐ É possível alterar nome, vCPUs e RAM de um perfil existente. ☐ A validação de unicidade de nome e de valores válidos é reaplicada na edição. ☐ A edição não corrompe benchmarks já executados que referenciam o perfil (resultados antigos preservam o snapshot da config usada).	
03	Como usuário, quero excluir um perfil, para manter a lista limpa.	☐ É possível excluir um perfil existente. ☐ Há confirmação antes da exclusão. ☐ Excluir um perfil não apaga resultados de benchmarks anteriores que o usaram.	
04	Como usuário, quero que o perfil seja validado contra o hardware real da máquina, para evitar configurar restrições impossíveis de executar.	☐ O sistema detecta vCPUs e RAM total disponíveis no host. ☐ Perfis que excedem o hardware real são bloqueados ou exibem alerta explícito. ☐ Uma margem de reserva para o SO é considerada (ex.: não permitir alocar 100% da RAM). ☐ O usuário é informado de quanto recurso está realmente disponível.	

EP-02 - Configuração de Benchmark

ID	User Story	CrITÉrios de Aceitação	Prioridade
05	Como usuário, quero selecionar até 3 modelos (textuais e/ou multimodais) da biblioteca Ollama, para compará-los no mesmo benchmark.	☐ É possível listar/buscar modelos disponíveis no Ollama. É possível selecionar de 1 a 3 modelos; ☐ selecionar um 4º é bloqueado. Modelos ainda não baixados podem ser puxados (progresso. ollama pull) com feedback de ☐ O sistema registra a tag/versão exata de cada modelo (para reprodutibilidade). Modelos textuais e multimodais são distinguíveis na seleção.	
06	Como usuário, quero configurar os prompts textuais do benchmark, para definir os cenários de decisão a serem avaliados.	☐ É possível adicionar, editar e remover prompts textuais. ☐ Cada prompt pode ter um identificador/rótulo. ☐ É possível associar uma resposta esperada (ground-truth) opcional ao prompt, para avaliação de qualidade. ☐ Os prompts ficam salvos na configuração do benchmark.	
6b	Como usuário, quero configurar cenários multimodais (imagem + pergunta/contexto), para avaliar modelos vision-language em tarefas de decisão	☐ É possível anexar uma imagem e associá-la a uma pergunta/contexto. ☐ A imagem é codificada corretamente (base64) para envio no campo Ollama. images da API ☐ Um cenário multimodal pode ser marcado como "pulável por falta de recurso" caso o modelo não caiba no perfil. ☐ Formatos de imagem comuns (PNG, JPG) são aceitos.	
07	Como usuário, quero definir o número de repetições (N) por célula, para garantir significância estatística.	☐ É possível definir N por benchmark, com default ≥ 20 . ☐ Valores menores que um mínimo recomendado exibem aviso (não impedem, mas alertam sobre perda de rigor). ☐ O N escolhido é registrado na configuração.	
7b	Como usuário, quero fixar os parâmetros de geração (temperature, seed, num_predict, num_ctx), para que a comparação entre modelos seja justa.	☐ É possível definir temperature (default 0) e/ou seed fixo. ☐ É possível definir num_predict (máximo de tokens gerados) num_ctx (janela de contexto) igual para todos os modelos. ☐ Os parâmetros aplicam-se igualmente a todos os modelos do benchmark.	
8	Como usuário, quero salvar a configuração completa do	☐ A configuração (perfis, modelos+versões, prompts, parâmetros, N) é salva em	

	benchmark, para poder reproduzi-la depois.	arquivo estruturado (JSON ou YAML). ☐ O arquivo salvo é suficiente para reexecutar o mesmo benchmark. ☐ A configuração recebe um identificador e timestamp	
9	Como usuário, quero carregar uma configuração salva, para repetir ou ajustar um benchmark anterior.	☐ É possível carregar um arquivo de configuração válido. ☐ Configurações inválidas ou corrompidas são rejeitadas com mensagem clara. ☐ Após carregar, é possível executar diretamente ou editar antes	

EP-03 - Execução de Benchmark

ID	User Story	Critérios de Aceitação	Prioridade
10	Como usuário, quero iniciar a execução de um benchmark a partir de uma configuração, para coletar as métricas dos modelos nos perfis definidos.	☐ A execução monta a matriz modelos × perfis × prompts × N corretamente. ☐ Cada inferência é disparada via API Ollama dentro do container restrito. ☐ O progresso geral é reportado (células concluídas / total). ☐ Ao final, todos os resultados estão persistidos e associados à configuração.	
11	Como sistema, quero aplicar as restrições de CPU/RAM do perfil via Docker, para simular fielmente o hardware edge.	☐ As flags --cpus e --memory (ou docker update) são aplicadas conforme o perfil. ☐ O limite de memória é efetivamente imposto pelo cgroup (verificável). ☐ Casos de swap/OOM provocados pelo limite são detectados e registrados. ☐ O container é derrubado e limpo ao fim de cada célula.	
11b	Como sistema, quero executar os testes de forma estritamente sequencial e isolada, para não contaminar as medições por concorrência de recursos.	☐ Apenas um container de teste roda por vez. ☐ O sistema não inicia a próxima célula antes de a anterior encerrar e liberar recursos. ☐ É documentado/avisado que processos pesados do host devem estar fechados durante a coleta.	
12	Como sistema, quero tratar falhas durante a execução, para que um erro pontual não invalide a bateria	☐ Falhas de OOM, timeout ou modelo que não carrega são capturadas. ☐ A célula que falhou é registrada com o	

	inteira.	motivo; a execução continua nas demais. ☐ O relatório final distingue células bem-sucedidas, puladas e falhadas. U	
13	Como usuário, quero configurar um timeout por inferência, para evitar que um modelo travado bloqueie o benchmark.	☐ É possível definir um timeout (em segundos) por execução. ☐ Execuções que estouram o timeout são abortadas e marcadas como falha por timeout. ☐ O timeout é registrado na configuração.	
13b	Como sistema, quero separar a medição de cold start da de warm inference, para refletir cenários edge distintos.	☐ A primeira inferência (modelo não residente) é medida como cold start. ☐ As execuções de warm-up iniciais são descartadas das estatísticas principais. ☐ O keep_alive é gerenciado para controlar a residência do modelo na RAM. ☐ Cold start e warm inference aparecem separados nos resultados.	

EP-04 — Coleta de Métricas

ID	User Story	Critérios de Aceitação	Prioridade
14	Como sistema, quero coletar latência e throughput da resposta da API Ollama, para medir a velocidade dos modelos.	☐ São extraídos total_duration, load_duration, prompt_eval_count, eval_count, eval_duration. ☐ Tokens/s e TTFT são calculados a partir desses campos. ☐ Respostas com campos ausentes/null são tratadas sem quebrar a coleta. ☐ Cada repetição é registrada individualmente (não só o agregado).	
15	Como sistema, quero coletar RAM pico e CPU% durante a inferência, para avaliar o custo computacional.	☐ RAM pico e CPU% médio são amostrados durante cada inferência (loop de amostragem via cgroup/docker stats). ☐ A frequência de amostragem é suficiente para captar o pico. ☐ Os valores são associados à célula e repetição corretas.	
15b	Como sistema, quero registrar clock e/ou temperatura da CPU junto das amostras, para detectar	☐ Clock e/ou temperatura são amostrados junto das métricas de recurso (quando disponível na plataforma).	

	e descartar medições contaminadas por throttling térmico.	☐ Esses dados são persistidos com as amostras. ☐ É possível, na análise, sinalizar amostras suspeitas de throttling.	
16	Como sistema, quero coletar o tamanho do modelo em disco e a resposta textual gerada, para permitir avaliação de espaço e qualidade.	☐ O tamanho em disco de cada modelo é registrado. ☐ A resposta textual completa de cada execução é persistida. ☐ O número de tokens gerados é registrado.	
17	Como sistema, quero persistir todos os resultados de forma estruturada, para permitir análise e reprodutibilidade.	☐ Todas as N repetições são armazenadas (não apenas médias/medianas). ☐ Cada registro referencia config, perfil, modelo+versão, prompt e índice de repetição. ☐ O esquema de persistência permite exportação posterior (CSV/JSON).	

EP-05 — Análise e Relatórios

ID	User Story	Critérios de Aceitação	Prioridade
18	Como usuário, quero exportar os dados crus em CSV, para análise externa e transparência	☐ É possível exportar todas as repetições em CSV. ☐ O CSV inclui identificadores de célula e todas as métricas coletadas. ☐ O arquivo abre corretamente em ferramentas comuns (Excel, pandas)	
19	Como usuário, quero exportar os resultados em JSON, para integração programática.	☐ Critérios de aceite: É possível exportar resultados completos em JSON estruturado. ☐ O JSON inclui config usada + métricas, garantindo reprodutibilidade.	
20	Como sistema, quero agregar as N repetições por célula em mediana, IQR e p95, para representar a distribuição em vez de um número único.	☐ Para cada célula são calculados mediana, IQR (ou quartis) e p95. ☐ A média não é usada como métrica principal de latência (pode constar como secundária). ☐ As execuções de warm-up descartadas não entram na agregação.	
20b	Como sistema, quero rodar testes	☐ Comparações de latência usam	

	estatísticos entre modelos, para sustentar afirmações de superioridade com evidência.	teste não-paramétrico (ex.: Mann-Whitney U). ☐ É reportado tamanho de efeito além do p-valor. ☐ Diferenças são apresentadas em termos práticos (ex.: "1.8× mais rápido na mediana").	
20c	Como usuário, quero visualizar a matriz comparativa e a fronteira de Pareto (latência × qualidade × recurso), para identificar trade-offs	☐ A matriz comparativa exibe as métricas-chave por modelo × perfil. ☐ Há um gráfico de fronteira de Pareto cruzando ao menos dois eixos (ex.: latência × qualidade). ☐ Células puladas/falhadas são visualmente distinguíveis. ☐ Os gráficos são interativos ou exportáveis como imagem.	
21	Como usuário, quero comparar dois benchmarks distintos, para avaliar mudanças entre configurações ou execuções.	☐ É possível selecionar dois benchmarks salvos e compará-los. ☐ As diferenças de métricas são exibidas lado a lado. ☐ Diferenças de configuração entre os dois são sinalizadas.	
22	Como usuário, quero avaliar a qualidade das respostas dos modelos, para que a comparação considere utilidade e não só desempenho.	☐ Para prompts com ground-truth, há avaliação objetiva (correção automática). ☐ Para prompts abertos, há uma rubrica simples (correção, utilidade, clareza). ☐ Opcionalmente, suporte a LLM-as-judge com documentação do viés. ☐ A nota de qualidade integra a matriz comparativa.	

EP-06 - Interface Web

ID	User Story	Critérios de Aceitação	Prioridade
23	Como usuário, quero telas visuais para gerenciar perfis de hardware, para criar/editar/excluir sem editar arquivos.	☐ CRUD de perfis disponível na interface (cobrindo US-01 a US-04). ☐ Validação contra hardware real exibida visualmente. ☐ Feedback claro de sucesso/erro nas operações.	

24	Como usuário, quero uma tela para configurar o benchmark, para montar o experimento de forma guiada.	☐ Seleção de modelos (até 3), prompts, parâmetros de geração e N na interface. ☐ Suporte a anexar imagens para cenários multimodais. ☐ Salvar/carregar configuração pela interface. ☐ Validações impedem iniciar um benchmark mal configurado.	
25	Como usuário, quero acompanhar a execução em tempo real, para saber o progresso e detectar problemas cedo.	☐ Progresso (célula atual / total) exibido durante a execução. ☐ Logs ou status por célula visíveis. ☐ Falhas e células puladas sinalizadas em tempo real. ☐ (Candidata a "nice-to-have" se a velocidade do time for menor.)	
26	Como usuário, quero um dashboard interativo de resultados, para explorar a matriz, os gráficos e os trade-offs	☐ Dashboard exibe matriz comparativa e visualizações da US-20c. ☐ É possível filtrar por modelo, perfil ou prompt. ☐ Botões de exportação (CSV/JSON) acessíveis. ☐ Resposta textual de cada modelo consultável para inspeção qualitativa.	

EP-07 - Infraestrutura e Qualidade (RNFs)

ID	User Story	Critérios de Aceitação	Prioridade
RNF-01	Como sistema, quero que o overhead do harness seja desprezível, para não contaminar as medições de inferência.	☐ O custo de CPU/memória do orquestrador é medido e documentado. ☐ O overhead não afeta significativamente as métricas dos modelos.	
RNF-02	Como sistema, quero que resultados sejam reproduzíveis, para garantir validade científica.	☐ Mesma config + seed + versões produz resultados estatisticamente equivalentes. ☐ Versões de modelos, Ollama e Docker são registradas em cada benchmark.	
RNF-03	Como usuário, quero rodar o framework em diferentes SOs com Docker, para não ficar preso a uma plataforma.	☐ Funciona em Linux e Windows (com Docker). ☐ Diferenças de coleta de métricas entre plataformas são documentadas.	
RNF-04	Como usuário, quero uma interface clara e consistente, para usar o framework sem documentação extensa.	☐ Fluxo principal (criar perfil → configurar → executar → ver resultado) é navegável sem instrução externa.	

		☐ Mensagens de erro são compreensíveis e acionáveis.	
RNF-05	Como desenvolvedor, quero logging estruturado, para depurar e auditar execuções.	☐ Eventos-chave (início/fim de célula, falhas) são logados com timestamp. ☐ Logs permitem reconstruir o que aconteceu numa execução.	
RNF-06	Como usuário, quero que meus dados fiquem locais e protegidos, para preservar privacidade.	☐ Dados de benchmark ficam armazenados localmente. ☐ Nenhum dado é enviado a serviços externos sem ação explícita do usuário (exceto LLMas-judge se ativado).	
RNF-07	Como desenvolvedor, quero testes automatizados do core, para evitar regressões.	☐ As camadas de orquestração e coleta têm testes automatizados. ☐ É possível rodar a suíte de testes com um comando.	
RNF-08	Como desenvolvedor, quero uma arquitetura extensível, para suportar runtimes além do Ollama no futuro.	☐ A camada de execução é abstraída de forma a permitir outro backend (ex.: llama.cpp, vLLM). ☐ (Backlog futuro — pós-entrega.)	